高雄科技大學 智慧商務系

資料結構 期末專題

Google 瀏覽器爬蟲

姓名:紀威宏

學號: C109156225

改善說明:

原先的程式是將陣列的詞依序訪問瀏覽器,再將瀏覽器找回來的網址做儲存,現在使用 hash 來存儲網址,這樣可以更快地查找和過濾網址。

```
va.2 🥏
                                                                                                                           final.py
• • ▷ ∨ □ ··
       > python introduction
        4.py
                                                        import requests import pandas as pd
        5.py
        Ⅲ 永續運輸.csv
                                                        import urllib.parse
        ☑ 依年齢層區分.docx
       Ⅲ 氣候變遷.csv
                                                        module = ["永續運輸",
                                                        def get_url(text1):
                                                            # geturl.py
headers = {'User-Agent':'Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKit/
                                                            url = f'https://www.google.com/search?q={text1}'
response = requests.get(url=url, headers=headers)
response.connection.close()
                                                            #如果decodeurl有符合arr的就不要 filtered_arr = [i for i in decodeurl if not any(j in i for j in arr)]
                                                             print(filtered_arr)
                                                            return filtered arr
> 大網
> 時間表
                                                              第 7 行,第 16 欄 空格: 4 UTF-8 LF (→ Python 3.10.9 ('venv': venv) ◎ Go Live 🙈 🔎
```

原程式碼

```
檔案總管
        ~ 廾阡分大數據實作__期末
                                                                   # geturl.py > print Aa ab. * 1
headers = {'User-Agence nowsers of the new print url = f'https://www.google.com/search?q={text1}'
response = requests.get(url=url,headers=headers)
         > venv
         4.py
                                                                    response.connection.close()
        Ⅲ 永續運輸.csv
                                                                    # read response
results = re.findall(r'sa=t&source=web&rct=j&url=(.*?)&',
         ☑ 依年齢層區分.docx
        Ⅲ 氣候變遷.csv
         final.py
                                                                    #如果decodeurl有符合arr的就不要
filtered_arr = [i for i in decodeurl if not any(j in i for j in arr)]
                                                               print(topurl)
return topurl
# s用名稱算排名
                                                                  scores = {}
for url in filtered_arr:
score = calculate_score(url)
scores[url] = score
                                                                    sorted_urls = sorted(scores.items(), key=lambda x: x[1], reverse=True)
return [url for url, _ in sorted_urls]
> 大綱
> 時間表
                                                                     第 42 行 · 第 15 欄 空格: 4 UTF-8 LF () Python 3.10.9 ('venv': venv) @ Go Live 😝 尽
```

重構後